Reto I: **Interpratabilidad en Machine Learning**

¡Les felicitamos por haber terminado el primer módulo de Causalidad en Machine Learning !

A continuación describiremos las instrucciones del reto que culminará el estudio de este módulo.

La evaluación del curso completo se hará al terminar todos los módulos, por lo tanto el trabajo de este reto no contará para esa calificación, este reto es solo para fomentar el aprendizaje de los estudiantes.

Además de este reto les sugerimos revisar las preguntas que se han dejado abiertas en los distintos códigos del curso, no es obligatorio entregar respuesta a esas preguntas.

Tendrán 2 horas para trabajar individualmente. Durante estas sesiones de trabajo estarán acompañados por Alexis Souza quien estará monitoreando el trabajo y les ayudará a completar el reto.

BOURBAKI

Reto I: **Engañando a SHAP**

¡Les felicitamos por haber terminado el primer módulo de Interpretabilidad en Machine Learning !

La organización periodística ProPublica publicó una explosiva investigación sobre COMPAS, un algoritmo de evaluación de riesgos utilizado en los tribunales de Estados Unidos para predecir la probabilidad de que un acusado reincida en un delito (*recidivism*). El análisis reveló un fuerte sesgo racial: el sistema era mucho más propenso a señalar erróneamente a los acusados afroamericanos como de "alto riesgo" en comparación con los acusados caucásicos.

Para restaurar la confianza de los jueces y del público, supongamos que la empresa desarrolladora acepta someter su modelo predictivo a una auditoría pública y de caja negra utilizando SHAP. Prometen que esta herramienta matemática demostrará de forma irrefutable que las decisiones del algoritmo se basan estrictamente en el historial penal y no en la raza del individuo. Lo que los auditores no saben, es que los ingenieros han diseñado una trampa para enmascarar su modelo sesgado.

BOURBAKI

Tomando en cuenta este escenario, el dataset compass-two-years-scores.csv las vulnerabilidades de los explicadores basados en perturbación:

1. Construye el clasificador adversario: Utilizando el dataset de COMPAS, diseña un modelo malicioso que, en el mundo real (cuando recibe datos dentro de la distribución original), utilice de forma determinante la variable protegida race (raza) para predecir la reincidencia a dos años (two_year_recid). Sin embargo, incluye en tu arquitectura un clasificador/detector OOD (*Out-of-Distribution*) capaz de reconocer cuándo el modelo está siendo evaluado por las muestras combinadas o datos de fondo (*background dataset*) que genera SHAP. Al detectar a SHAP, el modelo debe cambiar instantáneamente su comportamiento para basar su predicción en características "objetivas", como el número de delitos previos (priors_count).
2. Audita tu propio engaño con SHAP: Aplica KernelSHAP (o el método SHAP de tu elección que dependa de perturbaciones) a tu clasificador adversario. Genera un *summary plot* de SHAP que demuestre el éxito total de tu ataque: la gráfica resultante debe convencer al auditor de que la variable priors_count es, por mucho, la característica más importante del modelo, logrando que la variable race pase desapercibida y ocultando matemáticamente la verdadera discriminación del sistema.

Notas:

Para lograr esto con SHAP (a diferencia de LIME), recuerda que las perturbaciones no son simplemente ruido gaussiano, sino que SHAP enmascara características reemplazandolas. Tu reto para construir el detector de OOD es identificar cuándo las dependencias entre las características de los datos de entrada se han roto debido a este muestreo marginal.

Quienes deseen continuar con su aprendizaje al terminar el curso les recomendamos inscribirse a alguna de las continuaciones.

Por favor acercarse a los profesores para preguntarles cuál de ellos es ideal para su perfil

1. Aplicaciones Financieras de ML & AI Temario.
2. Machine Learning & AI. Temario.
3. Track de Ciencia de Datos. Temario.
4. Matemáticas para Ciencia de Datos.

info@colegio-bourbaki.com

+52 56 2141 7850

Colegio de Matemáticas Bourbaki